

Taller 1 – ETL con PySpark (Online Retail Dataset)

Aplicar un proceso ETL con PySpark utilizando un dataset real para explorar transacciones de ventas y clientes, empleando operaciones clave de Spark como **selección, filtros, agregaciones, agrupaciones y uniones**.

Dataset

- **Nombre:** Online Retail Dataset
- **Fuente:** UCI Machine Learning Repository
- **URL:** <https://archive.ics.uci.edu/ml/datasets/Online+Retail>
- **Formato:** Excel/CSV

Operaciones que deben aplicar en PySpark

1. **Lectura de datos**
 - `spark.read.format("csv")` o `spark.read.format("excel")`
2. **Selección de columnas**
 - `select()`
3. **Filtrado de datos**
 - `filter()` o `where()`
4. **Ordenamiento**
 - `orderBy()`
5. **Agregaciones**
 - `sum()`, `avg()`, `min()`, `max()`, `count()`
6. **Agrupación de datos**
 - `groupBy()` + `agg()`
7. **Creación de columnas derivadas**
 - `withColumn()`
8. **Uniones (joins)**
 - `join()` entre diferentes DataFrames
9. **Funciones de ventana (opcional)**

- `rank()`, `row_number()` para ranking de clientes o productos

10. Exportación de resultados

- `write.csv()`

Responde las siguientes preguntas utilizando Pyspark

1. ¿Cuál es el **número total de facturas** en el dataset?
2. ¿Cuál es el **número de clientes únicos**?
3. ¿Cuál es el **ingreso total** ($\text{Quantity} * \text{UnitPrice}$)?
4. ¿Qué **producto** fue el más vendido en cantidad?
5. ¿Cuál es el **cliente con mayor volumen de compra** en dinero?
6. ¿Cuáles son los **5 países** que más compran fuera de Reino Unido?
7. ¿Cuál es el **ticket promedio por factura**?
8. ¿Cuál es el **mínimo, máximo y promedio** de productos por factura?
9. ¿Qué **mes del año** tuvo más ventas?
10. ¿Cuál es el **porcentaje de facturas con devoluciones** (valores negativos en Quantity)?

Entregables

- Un **script para PySpark** con todas las operaciones solicitadas.
- Archivos CSV con los resultados de cada análisis.
- Documento corto con las conclusiones, link github del repositorio creado con los entregables.